


U1 Diffusion Models

從加噪到去噪

Diffusion Models and Their Applications · Week 3




資料是一些樣本點， p_{data} 是背後看不見的地形


看得到的資料



樣本在空間中的位置



整個空間上的 density



資料集只告訴我們哪些位置曾經出現；生成模型要描述整個空間，並從中抽出新的點。

什麼叫做「生」出一個新樣本？

不是把訓練資料複製一次，而是產生一個沒看過、但像是來自同一批資料的樣本。

圖片



複製一筆資料



(只是重複同一張圖)



生出一個新樣本


(沒看過，但像是來自同一批資料)

分子



複製一筆資料



(只是重複同一個分子)



生出一個新樣本


(沒看過，但仍符合這類分子的結構規則)

天氣



複製一筆資料

(只是重複同一張天氣圖)



生出一個新樣本


(沒看過，但屬於同一種天氣型態)

$$x_{\text{new}} \sim p_{\text{data}}$$

生成的目標不是重建某一筆資料，而是學會從整個分布再次抽樣。


為什麼不能直接學 $p_{\theta}(x)$ ？

資料只覆蓋很少的位置



$p_{\theta}(x)$ 卻要定義整個高維空間

知道密度，不等於會抽樣



計算 $p_{\theta}(x)$ 和得到 $x \sim p_{\theta}$ 是兩個不同問題


一個可用的生成模型，既要描述資料分布，也要提供實際的取樣方法。

密度只差一點，坡度可能差很多

密度幾乎一樣


$$\tilde{p}(x) = p(x)e^{0.01 \sin(1000x)}$$

$$\tilde{p}(x)/p(x) \in [e^{-0.01}, e^{0.01}]$$



score 的差卻很大


$$\nabla \log \tilde{p}(x) = \nabla \log p(x) + 10 \cos(1000x)$$



取樣器使用的是 $\nabla \log p(x)$ ；密度接近，不能保證取樣方向也接近。

上次想到的策略

1. 容易抽樣的分布 p_0



原本可能只是噪音
(沒有特定的結構)


transport map G_θ

學每一粒沙子要被搬到哪裡

目標是學到這個生成資料的 G_θ !

就像在海邊堆沙子：
不是創造沙子，而是重新安排沙子的位置

2. 搬到資料常出現的位置 p_{data}



粒子被搬到高密度、有意義的地方
因此整體分布就變成我們想要的 density distribution


生成時，我們不一定要先把 $p(x)$ 完整寫出來；我們可以學一個 map G_θ ，
把容易抽樣的粒子分布 p_0 推到資料分布 p_{data} ，讓抽到的粒子落在有意義圖片常出現的位置。

$$z \sim p_0 \rightarrow x = G_\theta(z), \text{ 使得 } G_{\theta\#} p_0 \approx p_{\text{data}}$$

上次有提到的錯誤範例


錯的訓練配對

z 與 x 隨機配對，彼此獨立 ($z \perp x$)



下一次迭代...

同一個區域的 z
可能配到完全無關的目標



目標函數與解

$$\min_{\theta} \mathbb{E}_{z \sim p_z, x \sim p_{\text{data}}} \|G_{\theta}(z) - x\|^2$$

$z \perp x$ (彼此獨立，隨機配對)

$$G^*(z) = \mathbb{E}[x] \quad (\text{與 } z \text{ 無關})$$

為什麼？

$$\begin{aligned} \mathbb{E}_x \|G(z) - x\|^2 &= \mathbb{E}_x [\|G(z)\|^2 - 2x^T G(z) + \|x\|^2] \\ &= \|G(z)\|^2 - 2G(z)^T \mathbb{E}[x] + \mathbb{E}[\|x\|^2] \\ &= \|G(z) - \mathbb{E}[x]\|^2 + \text{const.} \end{aligned}$$

對每個 z ，最小值在 $G(z) = \mathbb{E}[x]$ 。

街上的商店例子 (Diffusion Models | U1)

顧客分布在街上的不同位置 (x)



商店不知道下一位顧客會是誰
(沒有配對線索)，
而且移動成本是距離的平方。
在這種情況下，
最佳的固定商店位置是所有顧客位置的
質心 $\mathbb{E}[x]$ ，而不是為每位顧客開不同的店。

不同的 z 都會產生同一個平均影像



平均資料

$$\mathbb{E}[x]$$

(多個不同的 z
都得到相同的影像)


上次有提到的一個懵懵懂懂的想法

1. 沒有說明書，從散亂零件直接組成品：很難



只看散亂零件，要一次猜出完整成品很難，
而且可能有很多種組法。

2. 如果看到幾個中間狀態，就容易多了




如果我知道下一個較完整的中間樣子，就比較知道這一步該怎麼組。

相鄰兩個狀態只差一點點，
所以預測「上一步」或
「下一步中間態」比較容易。



給的中間狀態越多，組裝路徑就越清楚。

延續上次電光一閃的內容，今天會carefully走過：



Forward Process : 把資料逐步變成noise

Forward : 持續加一點點噪聲，直到變成 Gaussian noise



$t = 0$



$t = 100$




$t = 250$



$t = 400$



$t = 600$



$t = 800$



$t = T$

Reverse : 一次去噪很難；但一步一步去噪看起來可行

我們希望 Forward Process 做到什麼？



$$p(x) = ?$$

Probability

- random variable
- distribution
- $p(x)$

Good
Ideas
Build
Brighter
Futures
😊

拆解到最後應該要一樣散亂($x_T \sim p_T = \mathcal{N}(0, I)$)

從不同完整成品出發




不同的 x_0

(不同的可能成品 / 乾淨資料)

forward process :
逐步拆解

最後都變成散亂、好抽樣的零件



$x_T \sim p_T$

容易抽樣的分布

重點：不管原本是哪個成品，時間夠久後都會被拆成同一類「亂零件」分布。

$$q(x_T | x_0) \approx p_T(x_T)$$

也就是：最後的狀態幾乎不再依賴原本的成品 x_0 。


我們可以輕易製造拆解一半的狀態 x_t

從一個完整成品出發




x_0 ：完整成品
(已知起點 / 乾淨資料)


在時間 t ，可能有很多種中間態



一種可能的 x_t



一種可能的 x_t



一種可能的 x_t

$q(x_t|x_0)$ 是一個分布，不是一個唯一狀態

把時間推到 T ，這個 conditional 就變成上一頁的終點分布。

$$q(x_T|x_0) \approx p_0(x_T)$$

所以「最後會拆成什麼亂零件」，其實就是 $q(x_t|x_0)$ 在 $t = T$ 時的特例。

我們設計的 Forward Process 要做到

Forward : 持續加一點點噪聲，直到變成 Gaussian noise



$t = 0$



$t = 100$




$t = 250$




$t = 400$



$t = 600$




$t = 800$



$t = T$

1. 資料逐步被變成noise: $q(x_T|x_0) = p_T = \mathcal{N}(0, I)$
2. 容易製造出中間: $x_t \sim q(x_t|x_0)$

$q(x_t|x_0)$ 是怎麼被「逐步」決定出來的？



$q(x_t = \text{台中} | x_0 = \text{台北})$


$$q(x_t|x_0) = \int q(x_1, x_2, \dots, x_t|x_0) dx_1 dx_2 \dots dx_{t-1}$$

因為中間可能怎麼走不只一種，可以搭火車、騎車、坐公車、甚至一路走路；
所以 $q(x_t|x_0)$ 要把**所有可能的中間過程**都加總起來。

這個旅遊例子是離散選擇，所以寫「加總」；
連續情況時，對應的就是積分。

$q(x_1, x_2, \dots, x_t | x_0)$ 要怎樣才能拆解成
逐步 $q(x_s | x_{s-1})$ 呢？

$q(x_1, x_2, \dots, x_t | x_0)$ how to 等於 $\prod_{s=1}^t q(x_s | x_{s-1})$




Markov Chain：過去已成定局，未來只看現在！

考試分發只讀現在的成績單



學生從高一到高三的學習歷程被濃縮成一份現在的成績單；分發規則只讀現在的成績單，不會逐一檢視過去的每一堂課。

馬可夫鏈的性質



$$q(x_t | x_{t-1}, \dots, x_0) = q(x_t | x_{t-1})$$

一旦知道現在的狀態 x_{t-1} ，更早的過去 $x_0, \dots, x_{t-2}$ 對下一步 x_t 就不需要再另外查閱。

- **重點：**不是過去消失了，而是與下一步有關的過去資訊，已經被濃縮在現在。

馬可夫鏈的推導



- 1 $q(x_1, \dots, x_t | x_0)$
- 2 $= q(x_t, x_1, \dots, x_{t-1} | x_0)$
- 3 $= q(x_t | x_{t-1}, \dots, x_1, x_0) q(x_1, \dots, x_{t-1} | x_0)$

↑ 先用條件機率的鏈式法則：
 $p(a, b | c) = p(a | b, c) p(b | c)$
 這裡就是把 x_t 和 $(x_1, \dots, x_{t-1})$
 依照鏈式法則拆開，所以得到上面這一步。
- 4 $= q(x_t | x_{t-1}) q(x_1, \dots, x_{t-1} | x_0)$

↑ 這一步才用到馬可夫性質
 已知現在的狀態 x_{t-1} 時，
 更早的過去不再額外影響下一步 x_t 。
- 5 $= q(x_t | x_{t-1}) q(x_{t-1} | x_{t-2}, \dots, x_0) q(x_1, \dots, x_{t-2} | x_0)$
- 6 $= q(x_t | x_{t-1}) q(x_{t-1} | x_{t-2}) \cdots q(x_1 | x_0)$
- 7 $= \prod_{s=1}^t q(x_s | x_{s-1})$

意思是：整段路徑的聯合機率，可以拆成每一步「只看前一步」的轉移機率相乘。

它代表的意義



$$q(\text{屏東} | \text{高雄, 台南, 台中, 新竹, 台北}) \\ = q(\text{屏東} | \text{高雄})$$

例如從台北南下，可能經過不同路線：

路線 1：台北 → 新竹 → 台中 → 台南 → 高雄 → 屏東


路線 2：台北 → 新竹 → 台中 → 南投 → 高雄 → 屏東

無論是經過台南，或是經過南投，
 當你現在已經在高雄，要描述
 「下一步到屏東的機率」時，
 只需要看現在的狀態（高雄）；
 不需要重新把更早期是怎麼走到高雄全部再查一次。

- 不是說過去完全沒影響，而是與下一步有關的過去資訊，已經濃縮在現在的狀態裡。

要怎麼設計逐步 $q(x_t | x_{t-1})$ 才能保證剛剛想要的兩個性質呢？

1. 資料逐步被變成noise: $q(x_T | x_0) = p_T = \mathcal{N}(0, I)$
2. 容易製造出中間: $x_t \sim q(x_t | x_0)$



每一次縮放原本的信號，然後加上噪聲

先看直覺：狗狗照片會怎麼一路變成雜訊？



原始狗狗照片
(原始資料，非 Gaussian)

縮小一點
原本訊號
➡
再加一點
隨機噪點



輪廓還在，但淡一點
(加入少量噪點)

縮小一點
原本訊號
➡
再加一點
隨機噪點



更模糊、更多噪點
(只剩大致的狗狗結構)

重複
很多次
➡



幾乎只剩雜訊雲
(接近 Gaussian)




就像把一張狗狗照片反覆處理：

每次保留一點原本的樣子，再混入一點隨機雜訊。做很多次後，原本的細節會越來越淡，最後就只剩下接近 Gaussian 的隨機分布。

具體用數學寫下！

1 從一個點到另一個點

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \\ \epsilon_t \sim \mathcal{N}(0, I)$$




保留大部分 signal

加入一小份
Gaussian noise

β_t 很小

2 等價的條件高斯分佈

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$



3 變異數保持不變

$$\text{Var}(x_t) = (1 - \beta_t)I + \beta_t I = I$$

$$\begin{aligned} \text{Var}(\sqrt{1 - \beta_t} x_{t-1}) &= (1 - \beta_t) \text{Var}(x_{t-1}) \\ &= (1 - \beta_t)I \end{aligned}$$

+


$$\begin{aligned} \text{Var}(\sqrt{\beta_t} \epsilon_t) &= \beta_t \text{Var}(\epsilon_t) \\ &= \beta_t I \end{aligned}$$

$$\text{Var}(x_t) = (1 - \beta_t)I + \beta_t I = I$$

常用的幾個符號(超爆多...)


$$\alpha_t = 1 - \beta_t$$

這一步留下多少 signal




$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$$

累積留下多少 signal




$$\sigma_t^2 = 1 - \bar{\alpha}_t$$

累積加入多少 noise




$$\text{SNR}(t) = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}$$

signal 與 noise 的比例



不同的 schedule 比較



Schedule 決定的是沿路加噪的速度，不改變起點與終點。

逐步二連閃！連走兩步剛剛定義的transition

1 兩個 transition

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \varepsilon_t$$

$$x_{t-1} = \sqrt{\alpha_{t-1}} x_{t-2} + \sqrt{1 - \alpha_{t-1}} \varepsilon_{t-1}$$

2 把第二式代入第一式

$$x_t = \sqrt{\alpha_t \alpha_{t-1}} x_{t-2} + \underbrace{\sqrt{\alpha_t (1 - \alpha_{t-1})} \varepsilon_{t-1}}_{\text{來自 } \varepsilon_{t-1} \text{ 的 noise}} + \underbrace{\sqrt{1 - \alpha_t} \varepsilon_t}_{\text{來自 } \varepsilon_t \text{ 的 noise}}$$

3 使用獨立性

$$\text{Var} = \alpha_t (1 - \alpha_{t-1}) + (1 - \alpha_t) = 1 - \alpha_t \alpha_{t-1}$$

逐步 t 連閃！連走 t 步剛剛定義的 transition

從前幾步到一般情形（歸納）

2 步：
 $\alpha_t \alpha_{t-1}$



3 步：
 $\alpha_t \alpha_{t-1} \alpha_{t-2}$




t 步：
 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$

從乾淨影像與高斯噪聲得到 x_t

乾淨影像 x_0
(每個點是一個資料)



高斯噪聲 ε
(分佈是一團雲)



加噪後的影像 x_t



$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \varepsilon \sim \mathcal{N}(0, I)$$

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$


總結 Forward Process

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \varepsilon \sim \mathcal{N}(0, I)$$

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

$$\bar{\alpha}_t \rightarrow 0 \text{ as } t \rightarrow T,$$

$$\text{then } q(x_T|x_0) = \mathcal{N}(0, I)$$




知道怎麼Forward後，如何倒退走一步呢？



倒著走一步，為什麼是一個分布？

$$x_{t-1} \sim q(x_{t-1}|x_t)$$



知道現在的 x_t ，通常不能唯一決定前一步；reverse step 必須描述所有可能前一步的機率。


老師都說從定義出發

把原本的式子整理一下 $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \varepsilon_t$, $\varepsilon_t \sim \mathcal{N}(0, I)$


$$x_{t-1} = \frac{x_t - \sqrt{\beta_t} \varepsilon_t}{\sqrt{\alpha_t}}$$

抽一個新的 ε_t 代進去，不就好了？

1. 前向過程：一個 x_{t-1} 加上特定的 ε_t 得到 x_t



2. 固定 x_t ：重新抽 ε_t 會得到不相關的候選 x_{t-1}



看到 x_t 之後， ε_t 已經和它有關



看到最後的牌序 x_t ，
就已經包含了最後一次洗牌的線索，
所以最後一次洗牌不能重新獨立地再抽。

問題： ε_t 與 x_t 並不獨立

1. 前向過程的方程式

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \varepsilon_t$$

2. 計算協方差

$$\begin{aligned}\text{Cov}(\varepsilon_t, x_t) &= \text{Cov}(\varepsilon_t, \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \varepsilon_t) \\ &= \sqrt{\alpha_t} \text{Cov}(\varepsilon_t, x_{t-1}) + \sqrt{\beta_t} \text{Cov}(\varepsilon_t, \varepsilon_t) \\ &= \sqrt{\beta_t} I \neq 0\end{aligned}$$

$$\varepsilon_t \perp x_{t-1}$$


(所以 $\text{Cov}(\varepsilon_t, x_{t-1}) = 0$)

$$\text{Cov}(\varepsilon_t, \varepsilon_t) = I$$


(高斯白噪聲)

3. 散點圖： ε_t 與 x_t 有正相關

(a) ε_t vs. x_t (相關)




(b) ε_t vs. x_{t-1} (獨立)




小提醒：只有在不知道 x_t 時，才能重新抽一個獨立的 ε_t (就像重新洗牌)。一旦看到了 x_t ， ε_t 已經被「用了一部分」。

重新想一下，
我們知道 $q(x_t|x_{t-1})$ 要怎麼算出 $q(x_{t-1}|x_t)$



重新想一下，
我們知道 $q(x_t|x_{t-1})$ 要怎麼算出 $q(x_{t-1}|x_t)$

貝氏定理！



貝氏定理給過嗎？

$$q(x_{t-1}|x_t) = \frac{q(x_t|x_{t-1}) p_{t-1}(x_{t-1})}{p_t(x_t)}$$

會算：forward conditional


$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, \beta_t I)$$



由我們設計的 Gaussian forward step，
條件分布是已知的。

算不出： p_{t-1}


$$p_{t-1}(x_{t-1}) = \int q(x_{t-1}|x_0) p_{\text{data}}(x_0) dx_0$$



需要對所有可能的乾淨資料 x_0 積分，
得到時間 $t-1$ 的邊際分布；
 p_{data} 通常是複雜的多模態分布。

算不出： p_t

$$p_t(x_t) = \int q(x_t|x_0) p_{\text{data}}(x_0) dx_0$$



intractable:
式子寫得出，
但實際算不出。

同樣需要對所有 x_0 積分，
得到時間 t 的邊際分布；
也是複雜的多模態分布。

Forward transition 很簡單；難的是邊際分布包含了整個 p_{data} 的影響。

算不出來那我們用學的Y！

耶！Neural Networks！




算不出 reverse kernel, 那可以用學的嗎？

Objective: $J(\theta) = \mathbb{E}_{p_t} [D_{KL}(q(x_{t-1}|x_t) || p_{\theta}(x_{t-1}|x_t))]$

真實的一步

$$q(x_{t-1}|x_t)$$




在固定的 x_t 下，真實的 $q(x_{t-1}|x_t)$ 是一些帶權重的候選前一個點。

$$D_{KL}$$

讓兩個 conditional 靠近

模型的一步

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(\mu_{\theta}(x_t), \Sigma_{\theta}(x_t))$$




模型接收 x_t ，輸出自己的條件高斯分布 $p_{\theta}(x_{t-1}|x_t)$ 。

問題： target $q(x_{t-1}|x_t)$ 還是算不出。


把 reverse step 交給 neural network 之後，下一個問題是如何取得可訓練的 target。

**再回頭想一下，
Forward Process裡有沒有什麼東西沒用到？**



**再回頭想一下，
Forward Process裡有沒有什麼東西沒用到？**

x_0 !



出牌前，先看一下手牌有什麼！

1. 乾淨影像 x_0



x_0

一個真實的訓練樣本
(單一資料點)

2. 時間步 t



$t = 700$

t

從 $\{1, \dots, T\}$ 中
均勻取一個時間步

3. 高斯雜訊 ϵ



ϵ

一個標準高斯雜訊的實現
 $\epsilon \sim \mathcal{N}(0, I)$ (單一資料點)

4. 前向加噪 (可精確計算)

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sigma_t \epsilon$$



根據預定的噪聲排程
計算出 x_t


5. 帶雜訊的影像 x_t



x_t


對應時間步 t 的噪聲影像
(單一資料點)

訓練時，我們手上有
這四張牌：



取樣時沒有；
訓練時有


模型的輸入 (只有這兩個)



$p_\theta(x_{t-1} | x_t)$


不會把 x_0
輸入模型！

Target 看得到，模型看不到




為什麼這樣可以？


1 展開 KL	$\tilde{J}(\theta) = \mathbb{E}_{x_0, x_t} \left[D_{\text{KL}} \left(q(x_{t-1} x_t, x_0) \parallel p_\theta(x_{t-1} x_t) \right) \right]$ $= \mathbb{E}_{x_0, x_t} \mathbb{E}_{q(x_{t-1} x_t, x_0)} \left[\log q(x_{t-1} x_t, x_0) - \log p_\theta(x_{t-1} x_t) \right]$
2 第一項是 $-H(q)$ 不含 θ	$\mathbb{E}_{x_0, x_t} \mathbb{E}_q [\log q(x_{t-1} x_t, x_0)] = -\mathbb{E}_{x_0, x_t} [H(q(x_{t-1} x_t, x_0))]$ 不含 θ，為常數
3 θ -dependent term	$\tilde{J}(\theta) = C + \mathbb{E}_{x_0, x_t} \mathbb{E}_{q(x_{t-1} x_t, x_0)} [-\log p_\theta(x_{t-1} x_t)]$ $= C + \mathbb{E}_{x_0, x_t, x_{t-1}} [-\log p_\theta(x_{t-1} x_t)]$
4 對 x_0 平均	$\mathbb{E}_{x_0} [q(x_{t-1} x_t, x_0)] = \int q(x_{t-1} x_t, x_0) p(x_0 x_t) dx_0$
5 $= q(x_{t-1} x_t)$	$\int q(x_{t-1} x_t, x_0) p(x_0 x_t) dx_0 = q(x_{t-1} x_t)$
6 只差一個常數	$\tilde{J}(\theta) = \mathbb{E}_{x_t, x_{t-1}} [-\log p_\theta(x_{t-1} x_t)] + C = J(\theta) + C$ C 與 θ 無關



我們選擇的parametrization



1 $\tilde{\beta}_t$ 只由 schedule 決定



$\tilde{\beta}_t$ 由預先設定的 noise schedule 決定，與 x_0 或網路參數 θ 無關。

2 mean 中唯一未知的是 x_0

$$\tilde{\mu}_t(x_t, x_0) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} x_0 \right)$$

在 $\tilde{\mu}_t(x_t, x_0)$ 中， x_t 和 t 是已知的，唯一未知的就是 x_0 (資料內容)。

3 用 $\hat{x}_0$ 代替 x_0 ，就得到可學的反向 Gaussian


$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(\tilde{\mu}_t(x_t, \hat{x}_0(x_t, t)), \tilde{\beta}_t I)$$

讓網路從 (x_t, t) 預測 $\hat{x}_0$ ，代入 mean，就得到可學的反向高斯分佈；
 $\tilde{\beta}_t$ 保持不變，直接使用 schedule 的值。


兩個同變異數的Gaussian的KL

相同的 variance
(相同的寬度)

$$\tilde{\beta}_t I$$



$$q(x) = \mathcal{N}(\mu_2, \tilde{\beta}_t I)$$



相同的 normalization
常數與二次項曲率

$$\frac{1}{(2\pi\tilde{\beta}_t)^{d/2}} \exp\left(-\frac{1}{2\tilde{\beta}_t} x^\top x\right)$$

1 寫出 KL 的一般形式

$$D_{KL}(\mathcal{N}(\mu_1, \tilde{\beta}_t I) \parallel \mathcal{N}(\mu_2, \tilde{\beta}_t I))$$

2 相同的項會相減為 0

log normalization 相減 = 0

$$\log \frac{1}{(2\pi\tilde{\beta}_t)^{d/2}} - \log \frac{1}{(2\pi\tilde{\beta}_t)^{d/2}} = 0$$

共同的 $x^\top x$ 二次項相減 = 0

$$-\frac{1}{2\tilde{\beta}_t} x^\top x + \frac{1}{2\tilde{\beta}_t} x^\top x = 0$$

3 只剩下 mean 的距離

$$D_{KL} = \frac{1}{2\tilde{\beta}_t} \|\mu_1 - \mu_2\|^2$$

代入本題的 mean

$$\mu_1 = \tilde{\mu}_t(x_t, x_0), \quad \mu_2 = \tilde{\mu}_t(x_t, \hat{x}_0)$$

$$D_{KL} = w(t) \|\tilde{x}_0(x_t, t) - x_0\|^2$$

log normalization
 $x^\top x$ 二次項

相同的 variance $\tilde{\beta}_t I$

log normalization
 $x^\top x$ 二次項

相同的 variance $\tilde{\beta}_t I$



唯一剩下的差異

兩個 mean 的距離

$$\|\mu_1 - \mu_2\|^2$$




固定同一個 variance，KL 只比較兩個 mean 相隔多遠。

這次為什麼可以用L2來做regression了？

上一次：隨機配對（不相關）

每個 z 會隨機配對到不相關的訓練圖像 x_0 ，沒有告訴模型這是誰。



$$G^*(z) = E[x_0]$$

不論輸入哪個 z ，都輸出同一個平均圖像（常數）。

生活化理解：開街邊商店（上一次）




不知道是哪一位顧客
只能開一家固定的店...

最佳策略：
開在整個顧客分佈的中心
(平均)，對所有人都一樣。

這一次：forward 綁定

每個乾淨圖像 x_0 先經過 forward 過程變成自己的 x_t ，模型看到 x_t ，因此知道「這是誰的 noisy 版本」。




$$\hat{x}^*(x_t, t) = E[x_0 | x_t] = \int x_0 p(x_0 | x_t) dx_0$$

(Bayes 定理)

$$= \int x_0 \frac{q(x_t | x_0) p(x_0)}{p(x_t)} dx_0$$

輸出取決於輸入的 x_t （函數），不同的 x_t 會有不同的預測。

視覺化例子：E 字視力表（同一個 x_0 ，在不同噪聲強度下的後驗分佈）



同樣是 L_2 ：沒有線索 → 邊際平均（常數）；有 x_t 線索 → 條件平均（函數）。

期望值 $E[x_0|x_t]$

t 小：線索很多

x_t 只被輕微破壞，與某張圖非常相似 → 後驗機率高度集中

一筆資料



貓

$$p(x_0^{(i)} | x_t) = 0.96$$

一筆資料



鳥

$$0.03$$

一筆資料



兔子

$$0.01$$

一筆資料 (有雜訊的 x_t)



x_t

計算條件期望

$$\mathbb{E}[x_0 | x_t]$$

條件期望 (較清晰)



$$\mathbb{E}[x_0 | x_t]$$

t 大：線索很少

x_t 被嚴重破壞，可能來自很多張圖 → 後驗機率分散在多個資料上

一筆資料



貓

$$0.28$$

一筆資料



鳥

$$0.24$$

一筆資料



兔子

$$0.20$$

一筆資料



植物

$$0.18$$

一筆資料



汽車

$$0.10$$

一筆資料 (很吵的 x_t)



x_t

計算條件期望

$$\mathbb{E}[x_0 | x_t]$$

條件期望 (模糊的加權平均)



$$\mathbb{E}[x_0 | x_t]$$

後驗機率 (總和為 1)

貓： 0.28

鳥： 0.24

兔子： 0.20

植物： 0.18

汽車： 0.10

總和： 1.00

用剛剛學到的mean反著走回去

反向採樣流程（從 x_T 到 x_0 ）

每一步都用 (x_t, t) 預測乾淨影像 $\hat{x}_0$ ，並從反向分布採樣 x_{t-1} 。



x_0
乾淨影像
(資料分布)

...



x_{t-1}

←



x_t

神經網路預測乾淨影像

$$\hat{x}_0 = \hat{x}_\theta(x_t, t)$$

$x_t, t \rightarrow$

ϵ_θ

$\rightarrow \hat{x}_0$

從反向分布採樣（每一步都重新採樣 z ）

$$x_{t-1} = \tilde{\mu}_t(x_t, \hat{x}_\theta(x_t, t)) + \sqrt{\tilde{\beta}_t} z$$

$z \sim \mathcal{N}(0, I)$ （每一步新採樣，與前向的 ϵ_t 不同）



...

←



x_T
高斯雜訊
 $\mathcal{N}(0, I)$


● $z \sim \mathcal{N}(0, I)$ ：每一步新採樣的隨機雜訊

✗ 不是重新抽取前向過程的 ϵ_t （那是訓練時用的）

不同的parametrization

1 x_0 -prediction (預測乾淨資料)


$$\mathcal{L}_{x_0} = \mathbb{E} \|\hat{x}_\theta - x_0\|^2$$



直接預測乾淨的資料 x_0

2 ϵ -prediction (預測雜訊)


$$\mathcal{L}_\epsilon = \mathbb{E} \|\epsilon_\theta - \epsilon\|^2$$



$$\hat{x}_0 = \frac{x_t - \sigma_t \epsilon_\theta}{\sqrt{\bar{\alpha}_t}}$$

3 v -prediction (預測旋轉座標)

$$\mathcal{L}_v = \mathbb{E} \|v_\theta - v\|^2$$



$$v = \sqrt{\bar{\alpha}_t} \epsilon - \sigma_t x_0$$

三種表示的精確轉換關係


$$x_0 = \frac{x_t - \sigma_t \epsilon}{\sqrt{\bar{\alpha}_t}} \quad \epsilon = \frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{\sigma_t}$$

MSE 的 weighting 關係

$$\|\hat{x}_0 - x_0\|^2 = \frac{1}{\text{SNR}(t)} \|\epsilon_\theta - \epsilon\|^2$$

$$\text{SNR}(t) = \frac{\bar{\alpha}_t}{\sigma_t^2}$$

(x_0, ϵ) 平面中的幾何關係



資料使用聲名

本投影片與ChatGPT+Claude協作，並且使用了一張我朋友寵物的照片(已經過本人同意)

幾張圖中有發現不精確但不影響授課與理解，例如：台南的台。讓大家感受一下我們還可以把生成模型做得更好！

如果有發現任何錯誤或是符號上的問題，歡迎聯絡我！